

Einfluss automatisch annotierter Behavior-Features auf die präfix-basierte Früherkennung von Cybergrooming

Name: Mustafa Ugurluer
Matrikelnummer: 2699024
Department: Computer Science Department
Supervisor: Honorarprof. Dr.-Ing. Martin Steinebach
Responsible Staff: Mareike Bassenge

Date of submission: April 14, 2026
Darmstadt



TECHNISCHE
UNIVERSITÄT
DARMSTADT

Computer Science
Department
Fraunhofer SIT

1 Motivation

Cybergrooming, der gezielte Aufbau einer Vertrauensbeziehung zu Minderjährigen über digitale Plattformen mit dem Ziel sexueller Ausbeutung, ist ein zunehmendes Problem (Leiva-Bianchi et al., 2025; An et al., 2025a). Laut Bundeskriminalamt steigen die gemeldeten Fälle von sexuellem Missbrauch von Kindern in Deutschland kontinuierlich an (BKA, 2023). Besonders problematisch ist, dass Täter ihre Gespräche mit harmlosen Inhalten beginnen und ihre Absichten erst schrittweise offenbaren (An et al., 2025a; O’Connell, 2003). Einzelne Nachrichten enthalten daher oft keine eindeutigen Hinweise auf Grooming-Verhalten, was sowohl die menschliche als auch die automatische Erkennung erschwert.

In der psychologischen Forschung ist dieser schrittweise Prozess gut dokumentiert: Mehrere Modelle beschreiben typische Verhaltensphasen von Tätern, etwa den gezielten Vertrauensaufbau, das Testen von Grenzen oder die schrittweise Sexualisierung des Gesprächs (O’Connell, 2003; Lanning, 2010). Dieses Wissen wird in bestehenden technischen Erkennungssystemen jedoch kaum genutzt (An et al., 2025a; Leiva-Bianchi et al., 2025). Bisherige Ansätze fokussieren sich überwiegend auf die Analyse bereits abgeschlossener Chatverläufe und dienen damit primär der Strafverfolgung statt der Prävention (Leiva-Bianchi et al., 2025; An et al., 2025a). Für den effektiven Schutz von Minderjährigen ist jedoch die Früherkennung entscheidend: Das Ziel muss sein, laufende Gespräche in Echtzeit zu analysieren und eine Warnung auszulösen, bevor der eigentliche Schaden eintritt.

Mit dem Konzept der *Early Sexual Predator Detection* (eSPD) existiert ein Framework, das Chats präfix-basiert evaluiert, also nach jeder neuen Nachricht eine aktualisierte Einschätzung trifft (Vogt et al., 2021). Allerdings nutzen bisherige eSPD-Modelle ausschließlich den Rohtext als Eingabe, ohne psychologisch fundierte Verhaltensmerkmale einzubeziehen. Die Schließung dieser Lücke ist auch praktisch relevant: Plattformbetreiber stehen zunehmend unter regulatorischem Druck, wirksame Schutzmaßnahmen für Minderjährige zu implementieren, und Strafverfolgungsbehörden benötigen Werkzeuge zur Priorisierung verdächtiger Gespräche.

Vor diesem Hintergrund untersucht die vorliegende Arbeit folgende zentrale Forschungsfrage:

Verbessert die Integration automatisch annotierter Grooming-Behavior-Features die präfix-basierte Früherkennung von Cybergrooming?

Diese Frage wird durch drei Unterfragen operationalisiert:

1. **Operationalisierung:** Wie lassen sich die in psychologischen Phasenmodellen beschriebenen Grooming-Verhaltensweisen in automatisch annotierbare Behavior-Labels auf Turn-Ebene übersetzen?
2. **Erkennungsleistung:** Welchen Einfluss haben diese Behavior-Features auf Recall, Präzision und F_1 -Score eines BERT-basierten eSPD-Modells im Vergleich zu einer reinen Text-Baseline?
3. **Warnlatenz:** Ermöglichen die Behavior-Features eine frühere Warnung ohne die Präzision signifikant zu verringern?

2 Approach

2.1 State-of-the-Art (SOTA) / Related Work

2.1.1 Psychologische Grundlagen des Cybergrooming-Prozesses

Die psychologische Forschung beschreibt Cybergrooming als einen mehrstufigen Prozess mit wiederkehrenden Verhaltensmustern. O’Connell (2003) identifiziert sechs Phasen: *Friendship Forming*, *Relationship Forming*, *Risk Assessment*, *Exclusivity*, *Sexual Stage* und *Conclusion*, wobei der Täter das Opfer schrittweise vom Vertrauensaufbau über die Isolation bis hin zur sexuellen Ausbeutung führt (O’Connell, 2003). Lanning (2010) beschreibt in seinem für die Strafverfolgung entwickelten CEOP-Modell einen ähnlichen Ablauf mit Fokus auf die graduelle Eskalation und die gezielte Manipulation des sozialen Umfelds des Opfers (Lanning, 2010). Winters und Jeglic (2017) fassen diese Prozesse zusammen und betonen die Bedeutung der frühen Phasen für die rechtzeitige Erkennung, da die späteren sexuellen Phasen oft erst eintreten, wenn bereits erheblicher psychologischer Schaden entstanden ist (Winters and Jeglic, 2017).

Trotz ihrer Gemeinsamkeiten in den Kernphasen weisen neuere Arbeiten darauf hin, dass diese Modelle den Grooming-Prozess nicht als streng linearen Ablauf abbilden sollten. Moosburner et al. (2025) zeigen in ihrem systematischen Review, dass der Verlauf zyklisch und überlappend sein kann und stark vom Tätertypus sowie der Reaktion des Opfers abhängt (Moosburner et al., 2025). Ringenberg et al. (2021) stellen in ihrem Scoping-Review ergänzend fest, dass sich Grooming-Strategien durch die Digitalisierung verändert haben und ältere Modelle die heutigen Kommunikationsformen nur unzureichend abbilden (Ringenberg et al., 2021b).

Diese Strategien lassen sich als beobachtbare Verhaltensmuster auf Nachrichtenebene interpretieren und bilden damit eine theoretische Grundlage für die Ableitung von Behavior-Labels, wie sie in dieser Arbeit vorgeschlagen werden.

2.1.2 Datensätze und ihre Limitationen

Die Verfügbarkeit geeigneter Datensätze stellt eine der zentralen Herausforderungen im Bereich der Cybergrooming-Erkennung dar. Die meisten Studien greifen auf wenige, teils stark veraltete Korpora zurück (Leiva-Bianchi et al., 2025; An et al., 2025a). Der *PAN 2012 Competition*-Datensatz, der im Rahmen eines Wettbewerbs zur Identifikation von Sexual Predators erstellt wurde, enthält sowohl echte als auch synthetisch generierte Chatverläufe und diente lange als Benchmark. Die Chatprotokolle der Organisation *Perverved Justice*, in denen erwachsene Freiwillige sich als Minderjährige ausgaben, bilden eine weitere häufig genutzte Datenquelle (Leiva-Bianchi et al., 2025). Beide Datensätze weisen jedoch erhebliche Einschränkungen auf: Die Daten sind veraltet, die Kommunikationsstile entsprechen nicht den heutigen Plattformen, und die Gespräche wurden mit erwachsenen Lockvögeln statt mit realen Minderjährigen geführt (Ringenberg et al., 2021a).

McGhee et al. (2011) erstellten mit dem *ChatCoder2*-Datensatz ein Korpus, in dem Chatnachrichten mit Kategorien der Luring Communication Theory annotiert wurden (McGhee et al., 2011). Dieser Datensatz wird unter anderem von An et al. (2025) für Turn-Level-Annotationen verwendet (An et al., 2025b). Vogt et al. (2021) stellten mit dem *PANC*-Datensatz eine aufbereitete und erweiterte Version des PAN-2012-Korpus bereit, die speziell für die präfix-basierte Evaluation von eSPD-Modellen konzipiert wurde (Vogt et al., 2021).

Grundsätzlich verhindert die DSGVO aus berechtigten Gründen den öffentlichen Zugang zu realen Chatverläufen mit Minderjährigen, da es sich um höchst sensible Daten handelt. Dies hat zur Folge, dass die Forschung überwiegend auf Sting-Korpora und synthetische Daten angewiesen ist, deren Generalisierbarkeit auf reale Szenarien unklar bleibt (An et al., 2025a; Ringenberg et al., 2021a). Die vorliegende Arbeit verwendet den öffentlich verfügbaren PANC-Datensatz und muss diese Limitationen bei der Interpretation der Ergebnisse berücksichtigen.

2.1.3 Technische Ansätze zur Cybergrooming-Erkennung

Die technische Erkennung von Cybergrooming hat sich in den letzten Jahren erheblich weiterentwickelt. Frühe Ansätze setzten auf einfache Keyword-Filter, die bei bestimmten Schlagwörtern Alarm auslösten. Diese Methode ist im Kontext von Cybergrooming jedoch stark limitiert, da Täter ihre Gespräche in der Regel mit harmlosen Inhalten beginnen und mehrdeutige Formulierungen verwenden (Gupta et al., 2012).

Der Fokus verschob sich daraufhin auf Methoden des maschinellen Lernens. Bours und Kulsrud (2019) verglichen drei Analyseebenen – *message-based*, *author-based* und *conversation-based* – unter Verwendung verschiedener Klassifikatoren (SVM, Naive Bayes, Ridge Regression, neuronale Netze) und TF-IDF-basierter Features. Ihre Ergebnisse zeigen, dass eine Früherkennung grundsätzlich möglich ist, die Performance jedoch stark von Datensatz, Feature-Auswahl und Klassifikator abhängt. Besonders relevant ist ihre Beobachtung, dass *conversation-based* Ansätze, die Sequenzen von Nachrichten und deren zeitliche Abfolge berücksichtigen, subtile Verhaltensmuster besser erfassen als die Analyse einzelner Nachrichten (Bours and Kulsrud, 2019).

Die Meta-Analyse von Leiva-Bianchi et al. (2025) bestätigt, dass klassische Modelle wie SVM und Multilayer Perceptrons (MLP) hohe F_1 -Scores erzielen, macht aber gleichzeitig deutlich, dass die Generalisierbarkeit dieser Ergebnisse durch die verwendeten Datensätze eingeschränkt ist (Leiva-Bianchi et al., 2025). Heajun et al. (2025) betonen in ihrem interdisziplinären Review, dass die meisten bestehenden Arbeiten auf die Analyse bereits abgeschlossener Chatverläufe ausgerichtet sind und somit primär der Strafverfolgung dienen, während Ansätze zur echten Prävention durch Früherkennung deutlich seltener erforscht sind (An et al., 2025a).

Neuere Arbeiten setzen zunehmend auf Transformer-basierte Modelle wie BERT und RoBERTa, die semantische Zusammenhänge direkt aus dem Text erfassen und den Kontext über mehrere Nachrichten hinweg modellieren können (Devlin et al., 2019). Diese Modelle bieten den Vorteil, dass sie weniger auf manuelles Feature-Engineering angewiesen sind und potenziell robuster gegenüber sprachlicher Variation sind. Allerdings werden sie in der Cybergrooming-Forschung bislang kaum mit verhaltensbasierten Features kombiniert.

2.1.4 Early Sexual Predator Detection (eSPD)

Den engsten Bezugsrahmen für die vorliegende Arbeit bildet das Konzept der *Early Sexual Predator Detection* (eSPD), das von Vogt et al. (2021) formalisiert wurde. Im Unterschied zur klassischen Erkennung, die einen vollständigen Chatverlauf voraussetzt, evaluiert eSPD Gespräche *präfix-basiert*: Nach jeder neuen Nachricht wird der bisherige Verlauf erneut klassifiziert, sodass eine Entscheidung bereits nach wenigen Turns möglich ist. Vogt et al. stellten neben dem PANC-Datensatz auch ein BERT-basiertes Baseline-Modell sowie Evaluationsmetriken bereit, die neben der reinen Klassifikationsgenauigkeit auch die *Warnlatenz* – also die Anzahl der Nachrichten bis zur ersten korrekten Warnung – erfassen. Framework, Code und trainierte Modelle sind unter MIT-Lizenz öffentlich verfügbar (Vogt et al., 2021).

An et al. (2025) erweiterten diesen Ansatz mit *Speed-Control Reinforcement Learning* (SCoRL), einem Verfahren, das den optimalen Interventionszeitpunkt auf Turn-Ebene bestimmt, indem es gezielt die Balance zwischen Sensitivität und Spezifität steuert. Für ihre Evaluation nutzten sie unter anderem Turn-Level-Annotationen aus dem ChatCoder2-Datensatz, die auf den Kategorien der Luring Communication Theory basieren (An et al., 2025b). Ihr Ansatz zeigt, dass die explizite Optimierung des Warnzeitpunkts die Früherkennung verbessern kann, ohne die Gesamtgenauigkeit signifikant zu verringern.

2.2 Theoretical Framework / Foundational Concepts

Datensatz: Die Arbeit verwendet den PANC-Datensatz (Vogt et al., 2021), der aus den negativen (nicht-prädatorischen) Segmenten des PAN12-Datensatzes und den positiven (Grooming-)Konversationen des ChatCoder2-Datensatzes erstellt wird. PAN12 ist über Zenodo frei verfügbar, ChatCoder2 über chatcoder.com für Forschungszwecke. Die Preprocessing-Skripte zur Erstellung von PANC sind im eSPD-Datasets-Repository (GitLab, MIT-Lizenz) bereitgestellt.

Baseline-Modell: Als Baseline dient das BERT-base-Modell aus dem eSPD-Lab von Vogt et al. (2021), das Chatverläufe prefix-basiert klassifiziert. Über ein Sliding-Window-Verfahren wird nach jeder neuen Nachricht eine Vorhersage getroffen. Wird ein konfigurierter Schwellenwert (Skeptizismus) überschritten, löst das System eine Warnung aus. Code, Trainingspipeline und trainierte Modelle sind öffentlich verfügbar.

Behavior-Label-Schema: Auf Basis psychologischer Phasenmodelle wird ein reduziertes Label-Schema mit sieben Kategorien definiert: NEUTRAL, VERTRAUENSAUFBAU, INFORMATIONSGEWINNUNG, GEHEIMHALTUNG/ISOLATION, SEXUALISIERUNG, KONTROLLE/NÖTIGUNG und OFFLINE-ESKALATION. Dieses Schema annotiert beobachtbare Verhaltensweisen auf Turn-Ebene, nicht starre Phasen.

Automatischer Annotator: Für die automatische Annotation wird ein LLM-basierter Annotator entwickelt, der über Few-Shot-Prompting mit dem definierten Label-Schema, Definitionen und manuell annotierten Beispielen arbeitet. Zur Evaluation des Annotators dient ein Gold-Standard aus ca. 150–200 manuell annotierten Turns, bewertet mit Precision, Recall und F1-Score pro Label-Klasse.

Feature-Integration: Die automatisch annotierten Labels werden als Special Tokens vor den jeweiligen Turn-Text prepended (z. B. [VERTRAUENSAUFBAU] hey whats up). Das BERT-Modell wird unter identischen Bedingungen auf den modifizierten Daten trainiert. Der Vergleich beider Varianten unter denselben Testbedingungen isoliert den Einfluss der zusätzlichen Behavior-Features.

2.3 Methodology

Die Arbeit folgt einem fünfstufigen Vorgehen:

- (1) Label-Schema-Entwicklung: Ableitung des Behavior-Schemas aus psychologischen Modellen (O’Connell, Olson/LCT, Winters Jeglic) mit Fokus auf beobachtbare, annotierbare Verhaltensweisen.
- (2) Manuelle Annotation: Annotation von ca. 150–200 Turns aus verschiedenen Chats und Gesprächsphasen als Gold-Standard.

(3) Automatische Annotation: Entwicklung und Evaluation eines LLM-basierten Annotators (Few-Shot-Prompting über eine LLM-API). Evaluation gegen den Gold-Standard mit P/R/F1 pro Klasse. Anschließend Annotation des gesamten PANC-Datensatzes.

(4) Modelltraining: Training zweier Varianten des BERT-base-Modells im eSPD-Lab-Framework: Baseline (nur Rohtext) und erweiterte Variante (Rohtext mit prepended Behavior-Labels). Identische Hyperparameter und Train/Test-Splits.

(5) Evaluation: Vergleich beider Varianten anhand von Recall, F1-Score und Warnlatenz (F-latency nach Vogt et al.). Zusätzlich qualitative Analyse ausgewählter Gespräche, um zu untersuchen, bei welchen Behavior-Mustern die Features den größten Unterschied machen.

3 Zeitplan

Monat 1: Projektstart, Literatur & Label-Schema		
Woche 1	Kick-off & Scope	Erstes Treffen mit Betreuer*in: Forschungsfrage, Ziele und groben Zeitplan abgleichen. Zugang zu PANC-Datensatz und eSPD-Lab-Repository klären.
Woche 2	Literaturrecherche vertiefen	Gezielt Literatur zu Grooming-Phasenmodellen (O’Connell, Lanning, Winters & Jeglic), LCT und bestehenden eSPD-Ansätzen (Vogt et al., An et al.) sichten und annotierte Bibliographie aufbauen.
Woche 3	Label-Schema-Entwicklung	Aus den psychologischen Modellen das Behavior-Label-Schema mit sieben Kategorien ableiten. Definitionen, Abgrenzungen und Annotationsrichtlinien formulieren. Feedback vom Betreuer einholen.
Woche 4	Datensatz-Setup & Exploration	PANC-Datensatz erstellen (PAN12 + ChatCoder2 über die eSPD-Preprocessing-Skripte). Explorative Analyse: Gesprächslängen, Turn-Verteilung, Stichproben lesen.
Monat 2: Gold-Standard & Annotator-Entwicklung		
Woche 1	Manuelle Annotation (Phase 1)	Ca. 100 Turns aus verschiedenen Chats und Gesprächsphasen manuell mit dem Behavior-Schema annotieren. Schwierige Fälle dokumentieren, Richtlinien iterativ anpassen.
Woche 2	Manuelle Annotation (Phase 2)	Weitere 50–100 Turns annotieren, um den Gold-Standard auf ca. 150–200 Turns zu bringen. Konsistenz der eigenen Annotationen prüfen.
Woche 3	LLM-Annotator: Prompt-Design	Few-Shot-Prompts für den LLM-basierten Annotator entwickeln: Label-Definitionen, Beispiele aus dem Gold-Standard integrieren. Erste Tests mit kleiner Stichprobe.
Woche 4	LLM-Annotator: Evaluation	Annotator systematisch gegen den Gold-Standard evaluieren (Precision, Recall, F ₁ pro Klasse). Prompts iterativ optimieren, bis akzeptable Qualität erreicht ist.
Monat 3: Automatische Annotation & Modelltraining		
Woche 1	Vollannotation des PANC-Datensatzes	Den finalen LLM-Annotator auf den gesamten PANC-Datensatz anwenden. Qualitätskontrollen auf Stichprobenbasis durchführen.
Woche 2	Feature-Integration & Datenaufbereitung	Behavior-Labels als Special Tokens vor die Turn-Texte prepended. Zwei Datensatz-Varianten erstellen: Baseline (nur Text) und erweiterte Version (Text + Labels). Train/Test-Splits anlegen.

Woche 3	Baseline-Training	BERT-base-Modell im eSPD-Lab-Framework auf der reinen Text-Variante trainieren. Hyperparameter und Trainingskonfiguration dokumentieren.
Woche 4	Erweitertes Modell trainieren	Identisches Training auf der Variante mit Behavior-Labels. Sicherstellen, dass alle Bedingungen (Hyperparameter, Splits, Epochen) identisch sind.
Monat 4: Evaluation & Analyse		
Woche 1	Quantitative Evaluation	Beide Modelle auf dem Testset evaluieren: Recall, Precision, F ₁ -Score und Warnlatenz (F-latency) berechnen und vergleichen.
Woche 2	Qualitative Fehleranalyse	Ausgewählte Gespräche manuell analysieren: Bei welchen Behavior-Mustern verbessern die Features die Erkennung? Wo entstehen neue Fehler? Typische Fehlerquellen dokumentieren.
Woche 3	Ergebnisse aufbereiten	Tabellen, Diagramme und Visualisierungen der Ergebnisse erstellen. Statistische Signifikanz der Unterschiede prüfen.
Woche 4	Puffer & Nachexperimente	Pufferzeit für Nachexperimente, z. B. Ablation einzelner Label-Klassen oder Anpassung von Hyperparametern bei unerwartet schwachen Ergebnissen.
Monat 5: Schreiben der Arbeit		
Woche 1	Methodik & Datensatz schreiben	Kapitel zu Datensatz, Label-Schema, Annotator-Entwicklung und Modelltraining ausformulieren.
Woche 2	Ergebnisse schreiben	Ergebniskapitel mit allen quantitativen und qualitativen Befunden verfassen. Tabellen und Abbildungen einbinden.
Woche 3	Diskussion schreiben	Forschungsfragen beantworten, Ergebnisse im Kontext der Literatur interpretieren, Limitationen benennen, Ausblick formulieren.
Woche 4	Einleitung & Related Work finalisieren	Motivation und SOTA an die tatsächlichen Ergebnisse anpassen. Abstract und Zusammenfassung verfassen.
Monat 6: Revision & Abgabe		
Woche 1	Gesamtrevision	Vollständiger Durchlauf der Arbeit: Argumentationsfluss, Kohärenz, Zitationen und Formatierung prüfen.
Woche 2	Feedback einarbeiten	Entwurf an Betreuer*in senden. Feedback sorgfältig einarbeiten, sprachliche Verbesserungen vornehmen.
Woche 3	Letzte Korrekturen	Finale sprachliche und formale Überarbeitung. Abbildungsverzeichnis, Literaturverzeichnis und Anhang prüfen.
Woche 4	Puffer & Abgabe	Pufferzeit für unerwartete Probleme (Krankheit, technische Fehler). Finale PDF erstellen, Qualitätskontrolle, Abgabe.

Bibliography

- Haejun An, Marcos Silva, Qi Zhang, Arav Singh, Minqian Liu, Xinyi Zhang, Sarvech Qadir, Sang Won Lee, Lifu Huang, Pamela J. Wisniewski, and Jin-Hee Cho. 2025a. Toward integrated solutions: A systematic interdisciplinary review of cybergrooming research.
- Jinmyeong An, Sangwon Ryu, Heejin Do, Yunsu Kim, Jungseul Ok, and Gary Geunbae Lee. 2025b. Revisiting early detection of sexual predators via turn-level optimization. *arXiv:2503.06627*.
- BKA. 2023. Im fokus: Bundeslagebild sexualdelikte zum nachteil von kindern und jugendlichen.
- Patrick Bours and Halvor Kulrud. 2019. Detection of cyber grooming in online conversation. In *2019 IEEE International Workshop on Information Forensics and Security (WIFS)*.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. BERT: Pre-training of deep bidirectional transformers for language understanding.
- Aditi Gupta, Ponnurangam Kumaraguru, and Ashish Sureka. 2012. Characterizing pedophile conversations on the internet using online grooming. *arXiv:1208.4324*.
- Kenneth V. Lanning. 2010. *Child Molesters: A Behavioral Analysis for Professionals Investigating the Sexual Exploitation of Children*, 5 edition. National Center for Missing & Exploited Children.
- Marcelo Leiva-Bianchi, Nicolas Castillo, César A. Astudillo, and Francisco Ahumada-Méndez. 2025. Effectiveness of machine learning methods in detecting grooming: a systematic meta-analytic review. *Scientific Reports*.
- India McGhee, Jennifer Bayzick, April Kontostathis, Lynne Edwards, Alexandra McBride, and Emma Jakubowski. 2011. Learning to identify Internet sexual predation. In *International Journal of Electronic Commerce*.
- Maeve Moosburner, Christine Weber, Theresa Kuban, Sebastian Wachs, Alexander F. Schmidt, Sonja Etzler, and Martin Rettenberger. 2025. Understanding cybergrooming: A systematic review of perpetrator characteristics, strategies, and types. *Trauma, Violence, & Abuse*.
- Rachel O’Connell. 2003. A typology of child cybersexexploitation and online grooming practices.
- Tatiana Ringenber, Kathryn Seigfried-Spellar, and Julia Rayz. 2021a. Implications of using Internet sting corpora to approximate underage victims. In *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*. Association for Computational Linguistics.
- Tatiana R. Ringenber, Kathryn C. Seigfried-Spellar, Julia M. Rayz, and Marcus K. Rogers. 2021b. A scoping review of child grooming strategies: pre- and post-internet. *Child Abuse Neglect*.
- Matthias Vogt, Ulf Leser, and Alan Akbik. 2021. Early detection of sexual predators in chats. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics.
- Georgia M. Winters and Elizabeth L. Jeglic. 2017. Stages of sexual grooming: Recognizing potentially predatory behaviors of child molesters. *Deviant Behavior*.